ESPRIT – École Supérieure Privée d'Ingénierie et de Technologies

RAPPORT TECHNIQUE

Advanced Deep Learning – Final Project : AI Automation

BCMID Multimodal

Research Decision-Support Assistant

Système d'aide à l'exploration de rapports d'imagerie mammaire et de cas similaires

Projet Réalisé par :

Maissa Khemiri

Elyes Regaia

Rihab Ben Haj Slimene

Syrine Guemira

Aymen Dhieb

Neirouz Hanachi

Encadré par :

Mme Guesmi Oumayma

Module : Advanced Deep Learning

Établissement : ESPRIT – 5DS

Année universitaire 2026–2027

Remerciements

Nous tenons à exprimer nos sincères remerciements à notre enseignante pour son encadrement, ses conseils et les connaissances qu'elle nous a transmises tout au long du module *Advanced Deep Learning*. Ses orientations nous ont permis de mieux comprendre les concepts étudiés et de les mettre en pratique à travers ce projet.

Nous remercions également l'ensemble des membres de notre groupe pour leur collaboration, leur engagement et le partage de leurs compétences, qui ont contribué à la réalisation de ce travail.

Enfin, nous espérons que ce projet reflète les connaissances acquises durant cette formation ainsi que notre volonté de concevoir des solutions d'intelligence artificielle utiles, fiables et adaptées à des besoins concrets.

Table de matières

Remerciements **2**

Introduction générale **5**

Résumé 7

1 Contexte, cas d'usage et conformité au sujet **8**

1.1 Contexte, cas d'usage et conformité au sujet 8

1.1.1 Cas d'usage 8

1.1.2 Périmètre assumé 8

1.1.3 Conformité aux cinq exigences du sujet 8

2 Architecture globale et choix techniques **10**

2.1 Architecture globale du systéme 10

2.2 Architecture du système et choix techniques 11

2.2.1 Flux de traitement 11

2.2.2 Briques techniques et justification des choix 11

3 Plateforme d'automatisation (n8n) **13**

4 Données et prétraitement **14**

4.1 Présentation du corpus 14

4.2 Séparation des données sans fuite 14

4.3 Nettoyage et structuration des rapports 15

4.4 Alignement entre les images et les rapports 15

5 Approche RAG **16**

5.1 Corpus, chunking et indexation 16

5.2 Comparaison de deux stratégies de chunking (corpus pilote) 16

5.2.1 Comparaison de deux stratégies de chunking (corpus pilote) 17

5.2.2 Retrieval, reclassement et évaluation 17

5.2.3 Retrieval, reclassement et évaluation 18

6 Intégration multimodale **20**

6.1 Modalités et principe d'intégration 20

6.2 Recherche d'images 20
6.3 Exploration de la fusion multimodale 20
6.4 Échec instructif : fine-tuning BLIP-2 / QLoRA 21

7 Architecture multi-agents **22**
7.1 Architecture choisie 22
7.2 Boucle de correction 23
7.3 Justification des choix architecturaux 23

8 Prompt engineering **24**

9 Évaluation du système **25**
9.1 Défauts observés 25
9.2 Explicabilité (XAI) 25

10 Explicabilité (XAI) **27**
10.0.1 XAI-1 — Ablation « un passage en moins » sur le RAG 27
10.0.2 XAI-2 — Ablation de mots sur la similarité E5 28
10.0.3 XAI-3 — Explication de la recherche d'images CLIP 29

11 Sécurité, éthique et fiabilité **31**

12 Échecs, limites et perspectives **32**

13 Annexes **33**
13.1 Vue d'ensemble de la bibliothèque 33
13.2 P1.v1 — Réponse RAG documentaire 33
13.3 P1.v1 — Réponse RAG documentaire 34
13.4 P2.v2 — Générateur de l'agent 5 (FR/EN) + P2b reprise 34
13.5 P3.v1 — Analyse image + texte 35
13.6 P4.v2 — Générateur par passage (suivi et BI-RADS) 36
13.7 P5.v1 — Reclasseur (reranker) 37
13.8 P6.v1 — Légende BLIP-2 (fine-tuning) 37

14 Conclusion **41**

Introduction générale

L'intelligence artificielle connaît aujourd'hui une évolution importante, notamment grâce aux progrès du Deep Learning, des grands modèles de langage (*Large Language Models – LLMs*) et des systèmes capables de traiter plusieurs types de données. Associées aux plateformes d'automatisation, ces technologies permettent de concevoir des solutions intelligentes capables d'analyser des informations, de rechercher des connaissances pertinentes et d'assister les utilisateurs dans leurs prises de décision.

Dans le cadre du module *Advanced Deep Learning*, notre groupe a réalisé un projet d'automatisation intelligente portant sur la recherche et l'exploitation de données multimodales issues de l'imagerie mammaire. L'objectif est de développer un assistant capable de rechercher des informations dans des rapports médicaux, d'identifier des images similaires et de générer des réponses fondées sur les éléments retrouvés dans la base de connaissances. Ce système vise à faciliter l'exploration documentaire et l'accès à l'information, sans se substituer à l'expertise des professionnels de santé ni constituer un outil autonome de diagnostic.

Pour atteindre cet objectif, nous avons combiné plusieurs approches complémentaires. La génération augmentée par récupération (*Retrieval-Augmented Generation – RAG*) permet d'appuyer les réponses sur des passages extraits d'un corpus documentaire. Les techniques de recherche sémantique et lexicale contribuent à améliorer la récupération des informations pertinentes, tandis que les modèles multimodaux permettent de traiter les images médicales. Nous avons également étudié l'utilisation de plusieurs agents spécialisés, chargés respectivement de la recherche, de l'extraction des preuves, de la génération des réponses et de leur vérification. Enfin, l'automatisation du workflow avec n8n vise à organiser l'exécution des différentes étapes au sein d'un processus cohérent.

Ce projet nous a permis de mettre en pratique les principales notions abordées dans le module, notamment le *prompt engineering*, le RAG, l'intelligence artificielle agentique, le traitement multimodal et l'évaluation des systèmes intelligents. Une attention particulière a été accordée à la traçabilité des informations, à la vérification des réponses, à la gestion des erreurs et à la protection des données sensibles.

Ce rapport présente les choix techniques effectués et leur justification, l'architecture générale du système, les modèles et outils utilisés, les stratégies de recherche et de génération, ainsi que les méthodes d'évaluation mises en œuvre. Il expose également les limites identifiées et les améliorations envisageables afin de mieux apprécier les capacités et les contraintes de la solution développée.

Résumé exécutif

Nous avons conçu un assistant d'aide à la recherche documentaire en imagerie mammaire. À partir d'une question (en français ou en anglais) et/ou d'une image (mammographie ou échographie), il retrouve des rapports radiologiques pertinents et des cas visuellement proches, puis produit une réponse entièrement citée, vérifiée par un agent de contrôle et accompagnée d'un avertissement médical.

Le pipeline repose sur six agents spécialisés coordonnés par un orchestrateur à tableau noir partagé, sur un RAG hybride (embeddings multilingues et BM25 fusionnés par RRF, puis re-classement par LLM) et sur une recherche d'images basée sur CLIP. Le LLM fonctionne localement (Qwen2.5-7B-Instruct en 4 bits), garantissant qu'aucune donnée médicale ne quitte l'environnement de calcul.

Le rapport documente également les approches qui n'ont pas fonctionné : un fine-tuning de BLIP-2/QLoRA dont la perte diminue, mais dont les générations dégénèrent, une comparaison des stratégies de découpage (*chunking*) non discriminante sur le corpus pilote, ainsi qu'un échec de la recherche translingue lors de l'un des tests.

1. Contexte, cas d'usage et conformité au sujet

1.1 Contexte, cas d'usage et conformité au sujet

1.1.1 Cas d'usage Un radiologue, un interne ou un étudiant dispose d'une archive de rapports et d'images. Il souhaite répondre à des questions telles que :

> *« Quelles recommandations de suivi figurent dans les rapports de cas similaires ? »* ou
> *« Que décrivent les rapports des patientes dont l'échographie ressemble à celle-ci ? »*

Les réponses doivent être traçables : chaque affirmation renvoie à un passage source, et le système privilégie l'abstention plutôt que la génération d'informations non fondées.

1.1.2 Périmètre assumé Le jeu de données ne fournit pas d'étiquettes cliniques fiables, en l'absence d'un fichier de labels. Nous avons donc choisi de développer un système de recherche et de restitution de preuves plutôt qu'un classifieur.

Cette décision est structurante : elle permet d'éviter de présenter une prédiction non validée comme un diagnostic médical.

1.1.3 Conformité aux cinq exigences du sujet Le tableau suivant présente les cinq exigences du sujet, leur mise en œuvre dans le projet ainsi que les sections correspondantes du rapport.

[table]xcolor array colortbl

Exigence	**Réalisation**	**Section**
Plateforme d'automatisation	Workflow n8n déclenchable de bout en bout, appelant le pipeline d'agents.	3
Prompt engineering	Bibliothèque versionnée de six prompts, techniques utilisées, échecs observés et corrections apportées (Annexe A).	8, Ann. A
RAG	Corpus BCMID, comparaison des stratégies de découpage (*chunking*), E5 + Chroma, BM25 + RRF + re-classement (*reranker*) et évaluation (Annexe B).	5, Ann. B
Multi-agents	Six agents, tableau noir partagé et orchestrateur séquentiel avec mécanismes de reprise et de repli extractif.	7
Multimodalité	Exploitation des images avec CLIP, des rapports PDF et du texte ; expérimentation du fine-tuning de BLIP-2.	6

Table 1.1 – *Conformité du projet aux cinq exigences du sujet*

2. Architecture globale et choix techniques

2.1 Architecture globale du systéme

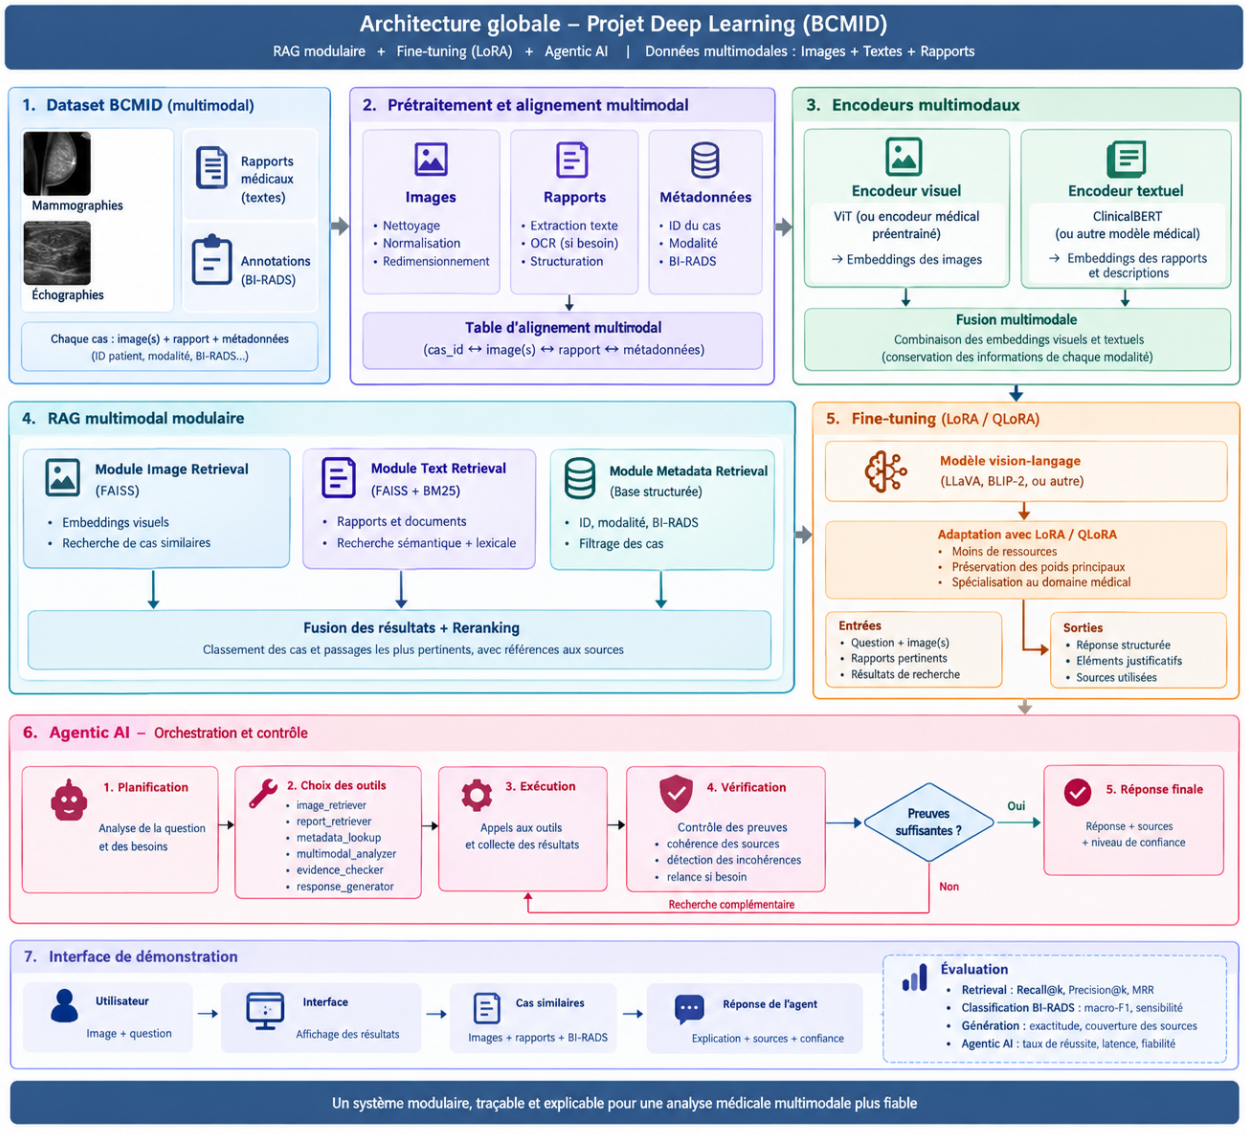


FIGURE 2.1 – *Architecture globale*

[T1]fontenc [utf8]inputenc [french]babel float tabularx array enumitem [table]xcolor

2.2 Architecture du système et choix techniques

2.2.1 Flux de traitement Le flux de traitement du système se déroule selon les six étapes suivantes :

(1) Normalisation de l'entrée : identification de la langue, de la modalité et de l'identifiant du patient.

(2) Recherche documentaire et visuelle : recherche de passages pertinents dans les rapports et, si une image est fournie, recherche de cas similaires.

(3) Agrégation des métadonnées : regroupement des métadonnées associées aux documents et aux cas retrouvés.

(4) Extraction des preuves textuelles : extraction de passages textuels exacts servant de preuves pour construire la réponse.

(5) Génération contrainte : génération d'une réponse fondée uniquement sur les passages récupérés.

(6) Vérification de la réponse : contrôle de la réponse produite afin de vérifier sa conformité aux sources.

En cas de refus du vérificateur, une nouvelle tentative est lancée. Si cette tentative échoue également, un mécanisme de repli extractif garantit une sortie toujours accompagnée de citations.

2.2.2 Briques techniques et justification des choix Le tableau 2.1 présente les principales briques techniques du système, les technologies retenues et les justifications de ces choix.

Brique	**Choix**	**Justification**
LLM	Qwen2.5-7B-Instruct, 4 bits NF4 (bitsandbytes), décodage glouton	Exécution locale, confidentialité des données médicales, coût nul et prise en charge du français et de l'anglais. Tient sur un GPU T4 ($\approx$ 5,6 Go).
Embeddings texte	intfloat/multilingual-e5-small (384 dimensions), préfixes `query:` et `passage:`, vecteurs normalisés	Modèle léger et multilingue permettant d'interroger un corpus anglais avec des questions en français. Similarité cosinus.
Base vectorielle	ChromaDB persistante, index HNSW avec similarité cosinus	Filtrage par métadonnées (split, patient, source) et persistance des données.
Recherche lexicale	BM25 implémenté localement ($k_1 = 1{,}5$; $b = 0{,}75$)	Repérage des termes exacts importants, comme « BI-RADS 3 », « biopsy » et « annual follow up ».
Fusion / rerank	RRF (constante 60), puis reclassement par le LLM avec sortie JSON	Fusion des classements sans calibrage des scores hétérogènes ; repli sur l'ordre RRF si le JSON est invalide.
Images	CLIP ViT-B/32 (512 dimensions), index Chroma des images d'entraînement	Recherche d'images médicales visuellement similaires, sans prétendre établir un diagnostic.
Extraction PDF	pypdf, reconstruction des sections « observations + OPINION »	Suppression de l'en-tête administratif et de la légende BI-RADS (section 4).
Exécution	Python, Kaggle (2 $\times$ T4), graine 42	Reproductibilité des expériences et exécution sur GPU.

Table 2.1 – *Choix technologiques et justifications*

3. Plateforme d'automatisation (n8n)

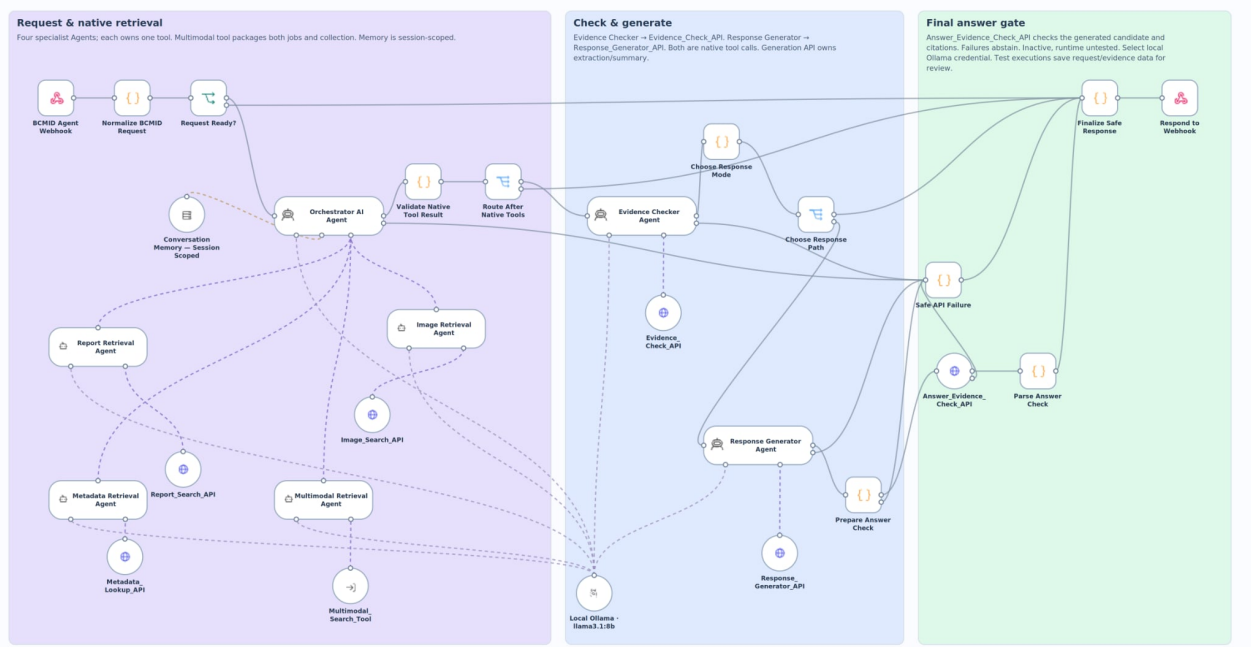


FIGURE 3.1 – *Architecture n8n*

n8n constitue l'ossature d'exécution : il reçoit la demande (question, image, modalité, identifiant patient facultatif), la valide, appelle le pipeline d'agents, gère les erreurs et renvoie la réponse citée avec son avertissement.

Le workflow est déclenchable sans exécuter de cellule manuellement, comme l'exige le sujet. Le cœur de calcul (agents, retrieval, LLM) reste en Python, car il nécessite un GPU et l'utilisation de modèles locaux. n8n assure ainsi le déclenchement, l'enchaînement des étapes, la gestion des erreurs et l'interface avec l'utilisateur.

4. Données et prétraitement

4.1 Présentation du corpus

Le corpus utilisé est le **BCMID**. Il comprend initialement 332 patientes, 2 001 images au format PNG (environ 13 Go) et 321 rapports au format PDF, dont 320 disposent de texte extractible.

Après contrôle de la qualité des données, un fichier vide ou illisible a été écarté et sept doublons exacts ont été supprimés. Aucun doublon entre patientes n'a été détecté. Le corpus final comprend ainsi **1 993 images**, réparties comme suit :

— **951 mammographies**, en niveaux de gris, d'une résolution approximative de $4\,728 \times 5\,928$ pixels ;
— **1 042 échographies**, au format RGBA, d'une résolution de 960×670 pixels.

4.2 Séparation des données sans fuite

La séparation des données est réalisée au niveau de la patiente, avec une graine aléatoire fixée à 42, afin d'éviter toute fuite d'information entre les ensembles d'entraînement, de validation et de test.

Table 4.1 – *Répartition des patientes et des images*

Ensemble	Patientes	Images
Entraînement	232	1 381
Validation	50	287
Test	50	325
Total	**332**	**1 993**

Des assertions vérifient que les trois ensembles sont disjoints et que chaque image, rapport et passage hérite du découpage de sa patiente. Seules les données d'entraînement alimentent les index de recherche, tandis que le jeu de test est réservé aux interrogations et à l'évaluation.

4.3 Nettoyage et structuration des rapports

Une première indexation par pages avait produit 903 passages. Cependant, elle mélangeait les en-têtes administratifs (identifiant de la patiente, médecin demandeur) et la légende BI-RADS, qui présente l'ensemble des catégories de 0 à 6. Cette dernière introduisait de fausses correspondances et perturbait l'extraction des catégories BI-RADS.

Pour corriger ce problème, les rapports sont reconstruits selon une structure composée des sections **« Observations »** et **« OPINION »**. Les en-têtes administratifs et les légendes BI-RADS sont retirés avant l'indexation.

Au total, **224 rapports** ont pu être structurés, répartis entre les ensembles comme suit :

— Entraînement : 160 rapports ;
— Validation : 32 rapports ;
— Test : 32 rapports.

Les autres rapports sont signalés comme non structurés, plutôt que complétés à partir d'informations supposées. Après ce prétraitement, l'index d'entraînement contient **502 passages**.

4.4 Alignement entre les images et les rapports

L'association entre les images et les rapports est établie au niveau de la patiente, et non au niveau de l'examen. La date de réalisation et la latéralité (sein gauche ou droit) n'ayant pas été vérifiées, cette association ne garantit pas une correspondance clinique exacte entre une image et un rapport.

Cette limite est enregistrée dans les métadonnées au moyen du champ `association_warning` et est également rappelée dans les avertissements fournis par le système.

Enfin, la catégorie BI-RADS extraite du texte est considérée comme un **candidat à vérifier**, et non comme une vérité terrain validée. Cette précaution permet de limiter les risques de conclusions erronées liés à l'incertitude de l'alignement image–rapport.

5. Approche RAG

5.1 Corpus, chunking et indexation

Choix du corpus : Les rapports radiologiques réels du corpus BCMID constituent la source de connaissances privilégiée pour ce cas d'usage. Ils présentent un vocabulaire spécialisé, une structure récurrente et un volume modeste, avec 160 rapports structurés dans l'ensemble d'entraînement. Ce volume permet d'utiliser un index léger, adapté aux besoins du projet.

Une première maquette reposait sur cinq fiches rédigées manuellement. Elle a permis de valider le fonctionnement de la chaîne RAG avant son application au corpus réel.

Stratégie de découpage : Le découpage (*chunking*) retenu s'appuie sur la structure en paragraphes des rapports, avec les paramètres suivants :

— **Unité de découpage :** paragraphes du rapport ;
— **Taille maximale :** 500 caractères ;
— **Chevauchement :** environ 100 caractères ;
— **Préservation des mots :** aucune coupure au milieu d'un mot.

Les rapports étant relativement courts, un paragraphe contient généralement une observation complète, notamment dans la rubrique *OPINION*, qui peut inclure une catégorie BI-RADS.

La première version du découpeur présentait des coupures à l'intérieur des mots. Une version corrigée, dite *« sûre aux frontières »*, a donc été mise en place et vérifiée sur l'ensemble des passages générés. Les contrôles ont confirmé l'absence de frontières cassantes et de passages introuvables dans leur document source.

5.2 Comparaison de deux stratégies de chunking (corpus pilote)

Plusieurs configurations de découpage ont été comparées sur le corpus pilote afin d'étudier leur influence sur la qualité de la recherche.

5.2.1 Comparaison de deux stratégies de chunking (corpus pilote)

Le tableau suivant compare quatre configurations de découpage selon le nombre de passages générés et trois métriques de recherche : Hit@1, Hit@3 et Mean Reciprocal Rank (MRR).

Table 5.1 – *Comparaison des configurations de chunking sur le corpus pilote*

Stratégie	Taille	Chevauchement	Passages	Hit@1	Hit@3	MRR
Taille fixe	200	50	10	0,80	1,00	0,90
Taille fixe	500	100	5	1,00	1,00	1,00
Taille fixe	1000	100	5	1,00	1,00	1,00
Paragraphes	500	100	5	1,00	1,00	1,00

Lecture honnête des résultats : Le découpage à 200 caractères fragmente les cinq documents pilotes en dix passages et dégrade le classement au premier rang (*Hit@1* = 0,80). Un *chunk* trop petit peut séparer une observation de son contexte.

Les trois autres configurations produisent exactement les mêmes cinq passages, puisque les documents pilotes mesurent moins de 500 caractères. Les résultats ne permettent donc pas de les départager. Nous ne concluons pas que 500 caractères constituent une taille optimale. Cette valeur a été retenue parce qu'elle correspond à la longueur d'un bloc d'observations des rapports réels et évite la fragmentation observée avec la taille 200. Une comparaison sur le corpus réel reste nécessaire.

5.2.2 Retrieval, reclassement et évaluation

Configuration du système : La recherche combine deux approches exécutées en parallèle : la recherche dense fondée sur E5 et la recherche lexicale BM25. Les candidats sont élargis à 20 résultats, puis fusionnés par la méthode *Reciprocal Rank Fusion* (RRF), avec un paramètre de fusion fixé à 60.

Un filtre strict limite ensuite les résultats au jeu d'entraînement, avant le reclassement par le modèle de langage (LLM), avec une sortie au format JSON. En cas d'échec du reclassement, le classement RRF est utilisé comme solution de repli.

Les paramètres appliqués aux agents sont les suivants :

— **Top-k textuel :** 5 ;
— **Seuil minimal de similarité :** 0,30 ;
— **Top-k image :** 5, avec une image par patiente.

Évaluation sur le corpus réel : L'évaluation sur le corpus réel repose sur six requêtes, correspondant à trois intentions exprimées dans deux langues. La référence utilisée est une référence faible : elle comprend les patientes dont le texte contient explicitement l'expression recherchée.

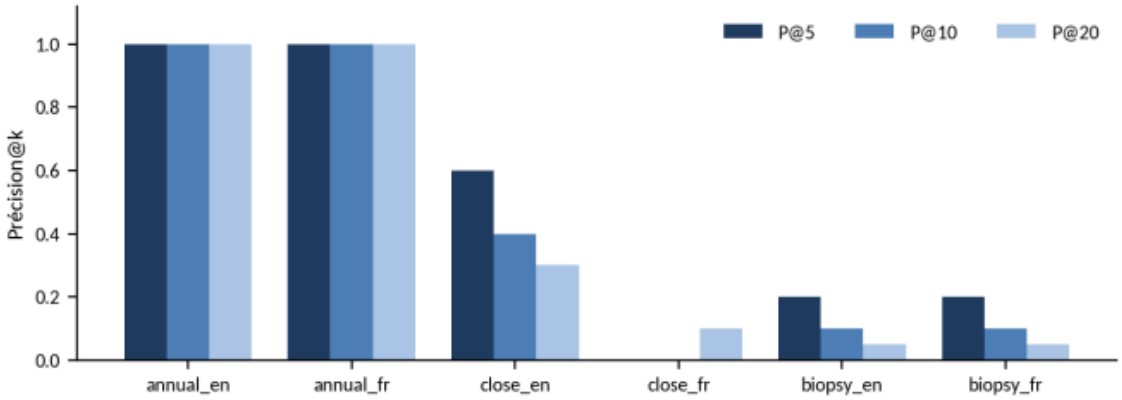


Figure 5.1 – *Architecture n8n*

Résultats et analyse : Les requêtes « annual » obtiennent $P@5 = P@20 = 1{,}00$ en anglais comme en français. « close follow up » est correcte en anglais ($P@5 = 0{,}60$; premier résultat pertinent au rang 1) mais échoue en français : aucun résultat pertinent avant le rang 11 ($P@5 = 0$). La recherche translingue est donc fragile sur les expressions peu fréquentes. « biopsy » ne compte que deux patientes de référence ; l'une est retrouvée au rang 1, l'autre jamais dans le top 20 (rappel = 0,5). Le rappel@k reste mécaniquement bas quand la référence est grande (114 patientes).

5.2.3 Retrieval, reclassement et évaluation

Sur quatre questions, le LLM seul répond de façon générique et, pour la question sur le contenu d'un rapport, invente une liste de rubriques « type » (identité du patient, date. . .) sans lien avec le

corpus. Le RAG répond à partir des documents indexés avec citation (`doc_004_c0000`, etc.) et, à la question hors périmètre (mot de passe d'un compte), répond exactement « Information non trouvée dans les documents », alors que le LLM seul improvise un refus poli sans contrôle. Les durées sont du même ordre (RAG : 1,2–5,1 s ; LLM seul : 3,4–9,4 s), les réponses du RAG étant plus courtes.

6. Intégration multimodale

6.1 Modalités et principe d'intégration

Le système combine trois modalités : images médicales (mammographies et échographies), PDF de rapports avec mise en page (extraction, reconstruction de la structure) et texte.

L'intégration repose sur un principe : le LLM ne voit jamais l'image. L'image sert à retrouver des cas proches ; ce sont les rapports liés à ces cas qui sont fournis au LLM. Cette conception est affichée dans le prompt (`You have NOT seen the submitted image`), ce qui empêche de présenter une description de pixels comme un fait.

6.2 Recherche d'images

Configuration et résultats : CLIP ViT-B/32 encode les 1 381 images d'entraînement. Pour 30 requêtes issues du test, le système retrouve cinq patientes distinctes par requête et obtient 100 % de résultats de même modalité dans le top-5.

Ce dernier chiffre est un contrôle de cohérence, pas une mesure de pertinence clinique : CLIP n'a pas été entraîné sur des images médicales.

Contrôle de la recherche : Un filtre de modalité (mammographie / échographie) et l'exclusion de la patiente requête empêchent l'auto-référence.

6.3 Exploration de la fusion multimodale

Nous avons aussi construit un vecteur patiente de 2 304 dimensions, comme alternative de recherche, composé de :

- ViT-Base : 768 dimensions pour les mammographies ;
- ViT-Base : 768 dimensions pour les échographies ;
- Bio_ClinicalBERT : 768 dimensions pour le texte.

Cette approche n'a pas été retenue dans la chaîne finale, faute de protocole d'évaluation permettant de la comparer à CLIP seul.

6.4 Échec instructif : fine-tuning BLIP-2 / QLoRA

Objectif et configuration. L'objectif était de générer un texte d'observations à partir d'une image. Le modèle utilisé est BLIP-2 (OPT-2.7B), avec un fine-tuning QLoRA configuré comme suit :

— Rang LoRA : $r = 8$;
— Facteur d'échelle : $\alpha = 16$;
— Modules ciblés : `q_proj` et `v_proj` ;
— Paramètres entraînables : 2,62 millions, soit 0,099 % du total ;
— Durée d'entraînement : 3 époques sur 160 patientes.

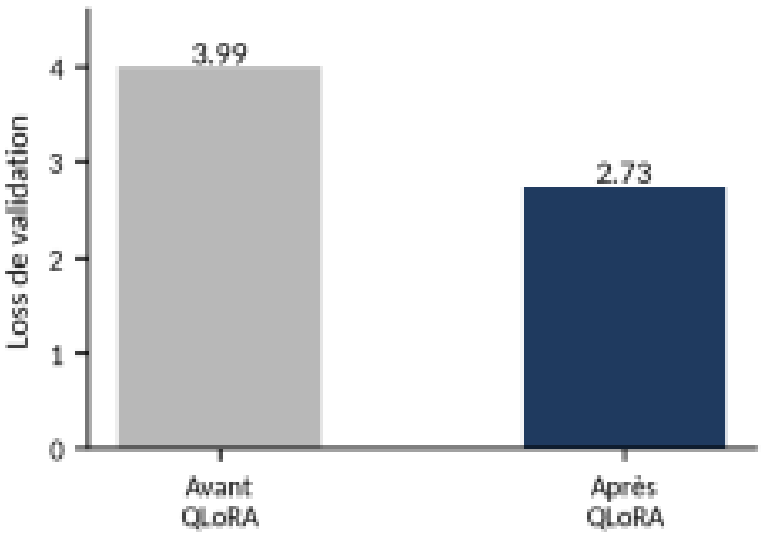


Figure 6.1 – *Perte de validation BLIP-2/QLoRA*

Résultats observés : La perte de validation baisse de 3,99 à 2,73, mais les générations après entraînement dégénèrent en boucles (« No suspicious lymph nodes » répété jusqu'à saturation). Avant entraînement, le modèle répétait déjà un gabarit sans rapport.

Une perte plus basse n'a donc pas produit de texte exploitable.

7. Architecture multi-agents

7.1 Architecture choisie

L'architecture choisie est une chaîne séquentielle pilotée par un orchestrateur, avec un tableau noir (*blackboard*) partagé.

Chaque agent lit et écrit des messages typés (auteur, rôle, contenu, tour). Chaque exécution renvoie un statut OK, SKIP ou ERROR et une durée. Un agent « non pertinent » (par exemple, la recherche d'images sans image) est ignoré.

Agent	**Rôle**	**Outils / entrées et sortie**
`report_retrieval`	Retrouver les passages de rapports pertinents	**Entrées :** E5 + Chroma, top-5, seuil 0,30. **Sortie :** passages + similarité.
`image_retrieval`	Retrouver les cas visuellement proches	**Entrées :** CLIP, filtre modalité, 1 image/patiente. **Sortie :** images + patiente + similarité.
`metadata`	Agréger BI-RADS candidat, modalités, nombre de rapports/images	**Entrées :** table d'alignement, catalogue structuré. **Sortie :** fiche patiente(s).
`evidence`	Extraire des citations exactes (suivi annuel/rapproché, biopsie, BI-RADS)	**Entrées :** expressions régulières sur les passages. **Sortie :** preuves par passage.
`generator`	Rédiger une réponse contrainte par les passages	**Entrées :** Qwen2.5-7B ; mode extractif si aucun passage. **Sortie :** réponse + identifiants cités.
`checker_response`	Valider citations, longueur, affirmations (BI-RADS, suivi, biopsie, négations)	**Entrées :** règles sur le corpus récupéré. **Sortie :** valide / problèmes.

TABLE 7.1 – *Rôle et fonctionnement des agents de l'architecture multi-agents*

7.2 Boucle de correction

Si le vérificateur refuse la réponse, le système applique une procédure de correction en deux étapes :

1. **Nouvelle génération :** une nouvelle réponse est générée avec une consigne renforcée imposant une citation par affirmation.
2. **Repli extractif :** à défaut, une réponse extractive est composée uniquement des éléments trouvés dans les passages, toujours citée et vérifiable.

Le nombre de reprises est borné. Une variante de l'analyse image + texte relance une recherche élargie (k_{img} de 3 à 5, k_{txt} de 4 à 8) quand les preuves sont insuffisantes, et s'abstient en cas de contradiction ou de citation invalide.

7.3 Justification des choix architecturaux

Pourquoi cette architecture, et pourquoi pas une autre ?

— **Appel monolithique.** Un appel monolithique mélangerait recherche, extraction et génération : impossible de localiser une erreur ni de vérifier la sortie indépendamment. Les échecs observés (patientes confondues, BI-RADS déformé) exigent un contrôle séparé de la génération.

— **Agent autonome de type ReAct.** Un agent autonome de type ReAct laisserait un modèle 7B quantifié choisir ses outils : appels incorrects probables, temps de calcul variable, comportement difficile à tester. Ici, l'ordre des étapes est connu à l'avance ; un enchaînement déterministe est plus fiable et se teste agent par agent.

— **Routeur ou hiérarchie maître–travailleurs.** Un routeur ou une hiérarchie maître–travailleurs apporterait de la complexité sans bénéfice : il n'y a que deux branches de recherche et leur combinaison est fixe. Le tableau noir suffit pour partager l'information.

— **Limite assumée.** Seuls le générateur et le reclasseur font appel au LLM ; les autres agents sont des outils déterministes. C'est volontaire (fiabilité en contexte médical), mais le système est donc agentique par la spécialisation et le contrôle, non par l'autonomie de décision.

8. Prompt engineering

Les prompts sont versionnés dans une bibliothèque (Annexe A) avec, pour chacun : rôle, technique, cas d'échec observés et correction.

Les techniques utilisées sont les suivantes :

- **Prompt d'ancrage (*grounding*) :** interdiction d'utiliser d'autres connaissances.
- **Sortie structurée :** citations entre crochets et format JSON pour le reclasseur.
- **Chaîne de garde-fous :** phrase d'abstention exacte et avertissement « image non vue ».
- **Consigne de reprise ciblée :** correction spécifique en fonction du problème détecté.
- **Exemple dans la consigne :** identifiant réel d'un passage donné en exemple de format.
- **Alias courts :** les alias `[E1]`, `[E2]` sont remplacés ensuite par les vrais identifiants, ce qui a supprimé les identifiants inventés par le modèle.

Les règles de langue (réponse dans la langue de la question) et la détection FR/EN sont gérées hors LLM pour ne pas dépendre de lui.

9. Évaluation du système

Composant	Protocole	Résultat
Retrieval texte (corpus réel)	6 requêtes, référence par règles	annual P@5 = 1,0 ; close_en 0,6 ; close_fr 0 ; biopsy 0,2 (Fig. 3)
Retrieval texte (pilote)	5 requêtes, $k = 1, 3, 5$	Hit@1 = Hit@3 = MRR = 1,0
Recherche d'images	30 requêtes test, index entraînement	5 patientes distinctes/requête ; même modalité : 100 % (cohérence)
Catalogue de métadonnées	10 tests unitaires (inconnu, filtres, modalité invalide, test bloqué. . .)	9 réussis, 1 ignoré (cas « plusieurs rapports » non disponible)
Vérificateur de preuves	5 cas : correct, BI-RADS altéré, citation inventée, mauvaise patiente, négation	4/4 cas non fondés détectés, 0 faux accord ; 3/3 tests de non-régression
Six agents + orchestrateur	Audit T1–T10 : 7 scénarios (bon LLM, reprise, repli, hallucination, image, erreurs)	Tous passés, dont deux intégrations réelles (texte ; image + texte)
Analyse image + texte	3 requêtes test (2 mammographies/échographies + suivi)	Citations toutes valides ; défauts relevés ci-dessous

Table 9.1 – *Synthèse des protocoles de test et des résultats obtenus.*

9.1 Défauts observés

Dans l'analyse image + texte, une réponse a été tronquée en cours de mot (« BIRA ») et un passage évoque une « tumeur rachidienne » issue d'un autre contexte clinique : les citations étaient valides mais le contenu doit rester rattaché à sa patiente. C'est la raison d'être du vérificateur (mauvaise patiente → abstention) et du découpage « une patiente par bloc ».

9.2 Explicabilité (XAI)

— **Ablation « un passage en moins » sur le RAG :** on retire chaque passage récupéré et on mesure le changement de la réponse. Résultat marquant : le passage au meilleur rang de

similarité n'explique que 2,8 % de la contribution, alors que le passage de rang 3 en explique 55,4 % : la similarité de retrieval n'est pas l'importance réelle pour la réponse.

— **Ablation de mots sur la similarité E5 :** le mot « mammaire » concentre 71 % de la contribution (0,843 de similarité globale) ; certains mots ont une contribution négative.

— **CLIP :** carte d'attention CLS→patchs et carte d'occlusion pour visualiser les zones qui pilotent la similarité visuelle. Ce sont des indices, non des preuves cliniques.

10. Explicabilité (XAI)

Dans un contexte médical, une réponse citée ne suffit pas : il faut aussi savoir ce qui a réellement pesé dans la similarité et dans la réponse. Nous avons mis en place trois analyses d'explicabilité, une par maillon du pipeline, toutes fondées sur la perturbation (retirer un élément et mesurer l'effet), méthodes indépendantes du modèle, adaptées à un LLM quantifié et à un encodeur dont on ne souhaite pas modifier l'architecture. Elles sont exécutées dans le notebook et leurs sorties sont exportées (JSON et figures dans le dossier `xai/`).

10.0.1 XAI-1 — Ablation « un passage en moins » sur le RAG

Question : parmi les passages fournis au LLM, lesquels ont réellement façonné la réponse ?

Méthode : pour la question « Quelles informations contient un rapport d'imagerie mammaire ? » ($k = 3$), on génère la réponse complète, puis k réponses en retirant à chaque fois un passage ($k + 1$ appels LLM, décodage glouton).

Pour chaque passage on calcule :

— **Importance texte** = 1 − similarité (`SequenceMatcher`) entre la réponse complète et la réponse sans ce passage ;

— **Importance citations** = 1 − Jaccard des identifiants cités ;

— **Importance combinée** = moyenne des deux ;

— **Part de contribution** = softmax de l'importance (température 0,1).

On compare enfin le rang de similarité de retrieval au rang d'importance (« découplage »).

Passage	Retrieval	Ablation	Contribution	Retrieval rank	Impact rank	Cited
Passage A	0.831	0.727	55.4%	3	1	Yes
Passage B	0.841	0.698	41.8%	2	2	Yes
Passage C	0.843	0.427	2.8%	1	3	No

Public copy: source-labeled chart omitted. See the anonymized XAI figures in docs/xai/.

Résultat : Le passage le mieux classé par la similarité (rang 1, 0,843) est le moins important pour la réponse : il n'est pas cité et son importance en citations est nulle (2,8 % de contribution). À l'inverse, le passage de rang 3 pèse 55,4 %. Le classement de retrieval et l'importance réelle sont découplés.

Interprétation : La similarité E5 mesure la proximité thématique (tous les passages parlent d'imagerie mammaire, d'où des scores très proches : 0,831 à 0,843) mais pas l'utilité pour la réponse. C'est un argument pour le reclassement par LLM (§5.3) et pour borner k à 3–5.

Réserve : L'importance texte est élevée pour les trois passages (0,79 à 0,90) car toute modification du contexte reformule la réponse ; l'importance en citations est la mesure la plus discriminante. Il s'agit d'une seule question, d'une seule exécution ; la température du softmax est un choix arbitraire qui change l'échelle des parts, pas l'ordre.

10.0.2 XAI-2 — Ablation de mots sur la similarité E5

Méthode : Pour la question précédente et son passage de rang 1, on retire un mot à la fois, on ré-encode la requête (préfixe « query : ») et on mesure la chute de similarité cosinus ; la part relative normalise les contributions positives.

Résultat : (Similarité globale 0,8429) :

Mot retiré	mammaire	d'imagerie	inform.	un	rapport	contient	?	Quelles
Contribution	+0,0454	+0,0117	+0,0037	+0,0017	+0,0013	−0,0102	−0,0112	−0,0186
Part relative	71,2 %	18,3 %	5,8 %	2,7 %	2,0 %	0	0	0

Un seul terme de contenu, « mammaire », explique 71 % de la similarité ; le mot interrogatif « Quelles » et la ponctuation ont une contribution négative (les retirer rapproche la requête du passage). L'encodeur s'appuie donc sur les mots de contenu et non sur la forme de la question, ce qui est cohérent avec notre choix d'ajouter une composante lexicale (BM25) — argument qualitatif, l'effet du BM25 n'étant pas mesuré (§5.3).

Limites : découpage par espaces (« d'imagerie » reste un seul mot), un seul couple question–passage, effets d'interaction entre mots ignorés.

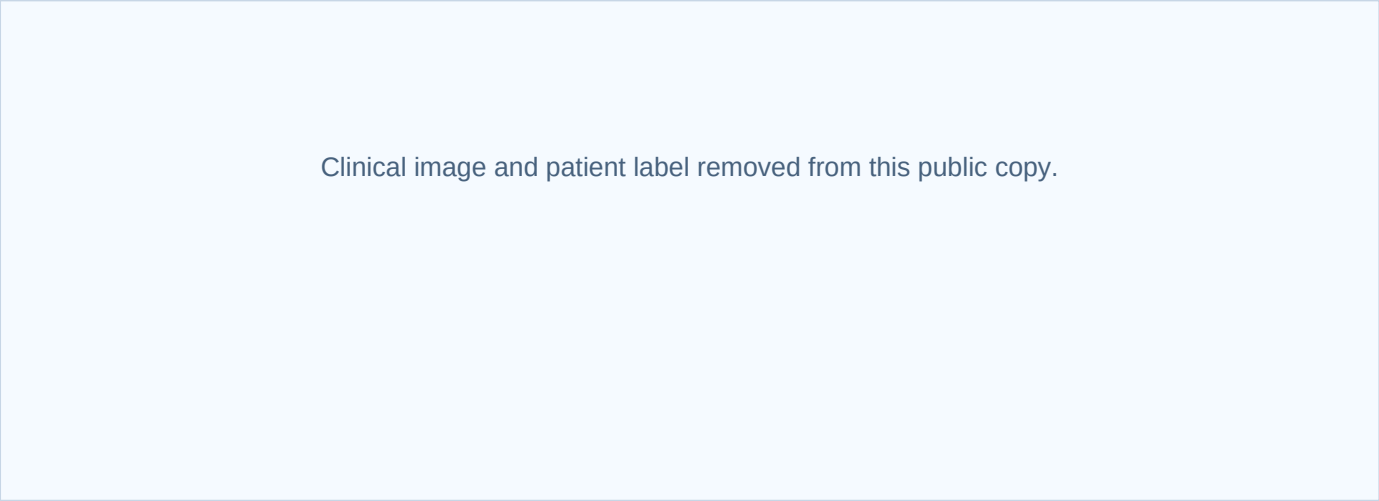
10.0.3 XAI-3 — Explication de la recherche d'images CLIP

Méthodes.

(a) **Carte d'attention :** attention du jeton CLS vers les 49 patchs de la dernière couche du ViT, moyennée sur les têtes (le modèle doit être chargé en attention « eager » pour exposer les poids ; vérification défensive ajoutée).

(b) **Carte d'occlusion :** grille 6×6, chaque cellule masquée en noir, importance = $1 -$ similarité cosinus avec l'embedding de l'image d'origine (37 passes avant).

Les deux cartes sont normalisées min–max.



Public copy: the image-specific result is omitted with the example image. The report discusses limitations of attention and occlusion maps, including sensitivity to device annotations and image artifacts.

d'acquisition ; deux images proches peuvent l'être parce qu'elles viennent du même échographe ou du même réglage, pas parce que les lésions se ressemblent.

Cela justifie trois choix de conception : le LLM ne voit jamais l'image, les résultats image sont présentés comme « cas proches » et non comme diagnostic, et les avertissements rappellent que l'association image–rapport se fait au niveau patiente.

Limites : image redimensionnée en 224×224 (déformation des mammographies, très grandes), une seule image analysée, cartes qualitatives non validées par un radiologue.

Apport global de l'XAI :

1. Elle montre que la similarité n'est pas l'utilité (XAI-1), ce qui oriente le reclassement et le choix de k.
2. Elle identifie les mots qui pilotent la recherche (XAI-2).
3. Elle révèle un risque de raccourci dans la recherche d'images (XAI-3).

Coût : XAI-1 demande $k+1$ générations LLM par question, ce qui limite un usage systématique ; une application à grande échelle (plusieurs dizaines de questions) et une validation par un expert restent à faire. "'

11. Sécurité, éthique et fiabilité

Risque	Mesure mise en œuvre	Preuve / limite
Fuite de données médicales	LLM, embeddings et index exécutés localement ; aucun appel d'API externe dans le pipeline ; en-têtes retirés des rapports indexés	Pseudonymisation partielle : le texte libre n'a pas été audité intégralement
Fuite d'évaluation (leakage)	Découpage par patiente ; assertions de disjonction ; index limité à l'entraînement ; l'outil de métadonnées refuse le split test pour les agents	Test « agent tool blocks test split » réussi
Hallucination	Ancrage strict, citations obligatoires, abstention exacte, vérificateur (BI-RADS, suivi, biopsie, négation), repli extractif	Cas altérés : 4/4 détectés ; la vérification reste fondée sur des règles
Mauvaise attribution entre patientes	Réponses séparées par patiente ; contrôle « mauvaise patiente → abstention »	Test réussi ; association image–rapport au niveau patiente
Usage clinique abusif	Avertissement systématique (FR/EN) ; BI-RADS « candidat à vérifier » ; le LLM ne voit pas l'image	Prototype de recherche, non validé cliniquement
Injection dans les documents	Consigne : les passages sont des données ; sortie contrainte (identifiants valides)	Pas de test adversarial dédié : limite reconnue
Robustesse	Statuts OK/SKIP/ERROR explicites (jamais de liste vide silencieuse), validation des entrées, longueurs bornées, reprises ≤ 2	Tests d'erreurs passés
Secrets	Aucune clé dans le code du pipeline ; identifiants n8n gérés par credentials	À confirmer pour le workflow n8n

12. Échecs, limites et perspectives

— **Fine-tuning BLIP-2 :** échec qualitatif malgré une perte décroissante ; seulement 160 patientes et aucun alignement au niveau de l'examen.

— **Chunking :** comparaison non discriminante sur le pilote ; à refaire sur 502 passages réels avec un jeu de questions annoté par un expert.

— **Retrieval translingue :** échec de « close follow up » en français ; pistes : traduction de la requête, BM25 bilingue, modèle E5 plus grand.

— **Évaluation :** références faibles par règles ; l'effet du BM25 et du reranker n'est pas chiffré ; CLIP non évalué sur la pertinence clinique.

— **Données :** alignement au niveau patiente ; 96 rapports non structurés exclus ; pas de labels, donc pas de métrique diagnostique.

— **Perspectives :** annotation experte, comparaison dense / hybride / reranker, encodeur d'images médical, tests d'injection de prompt, journalisation des décisions du vérificateur dans n8n.

Conclusion

Nous avons livré un pipeline multimodal complet dont la valeur tient moins à la complexité qu'au contrôle : chaque réponse est ancrée, citée, vérifiée et assortie d'un avertissement, et le système s'abstient quand les preuves manquent. Les expériences négatives (BLIP-2, chunking, retrieval translingue) ont directement orienté nos choix finaux.

13. Annexes

Annexe A — Bibliothèque de prompts (versionnée)

Convention : P#.vN. Les prompts sont reproduits sous forme condensée mais fidèle (règles conservées). Les cas d'échec marqués « observé » proviennent des essais du notebook ; ceux marqués « prévenu » sont des règles ajoutées pour éviter un défaut identifié sur les données.

13.1 Vue d'ensemble de la bibliothèque

ID	Rôle	Technique	Version
P1	Réponse RAG documentaire (prototype)	Ancrage, citation, abstention exacte	v1
P2	Générateur de l'agent 5 (FR/EN)	Ancrage, exemple de format, interdits cliniques, reprise	v2 (+ P2b reprise)
P3	Analyse image + texte	Garde-fous « image non vue », identifiants I/R	v1
P4	Générateur par passage	Sortie structurée, alias [E#], reprise	v2
P5	Reclasseur (reranker)	Sortie JSON seule, repli	v1
P6	Légende BLIP-2 (fine-tuning)	Consigne fixe d'instruction	v1

13.2 P1.v1 — Réponse RAG documentaire

Rôle : Répondre à une question sur le corpus à partir des seuls passages récupérés.

Technique : Role prompting léger, ancrage (grounding), citation obligatoire, abstention à phrase exacte.

Échecs et correction : Observé : sans RAG, le LLM invente des rubriques génériques (identité du patient, date. . .). Correction : contexte restreint aux passages + phrase de refus fixe.

Avant / après : LLM seul : liste générique « type »; avec P1 : contenu issu des rapports, cité (doc_004_c0000). Question hors périmètre → « Information non trouvée dans les documents. »

Prompt utilisé :

```
Tu réponds uniquement à partir des passages fournis.
Cite l'identifiant du passage entre crochets pour chaque affirmation.
Si l'information est absente des passages, réponds exactement :
"Information non trouvée dans les documents."
PASSAGES: {contexte} QUESTION: {question}
```

13.3 P1.v1 — Réponse RAG documentaire

Rôle : Répondre à une question sur le corpus à partir des seuls passages récupérés.

Technique : Role prompting léger, ancrage (grounding), citation obligatoire, abstention à phrase exacte.

Échecs et correction : Observé : sans RAG, le LLM invente des rubriques génériques (identité du patient, date. . .). Correction : contexte restreint aux passages + phrase de refus fixe.

Avant / après : LLM seul : liste générique « type »; avec P1 : contenu issu des rapports, cité (doc_004_c0000). Question hors périmètre → « Information non trouvée dans les documents. »

Prompt :

```
Tu réponds uniquement à partir des passages fournis.
Cite l'identifiant du passage entre crochets pour chaque affirmation.
Si l'information est absente des passages, réponds exactement :
"Information non trouvée dans les documents."
PASSAGES: {contexte} QUESTION: {question}
```

13.4 P2.v2 — Générateur de l'agent 5 (FR/EN) + P2b reprise

Rôle : Rédiger la réponse finale citée à partir des passages et de la liste des images similaires.

Technique : Ancrage ; format de citation imposé avec exemple réel ; interdits cliniques explicites ; phrase d'abstention exacte ; consigne de reprise ciblée.

Échecs et correction : Observé/prévenu : réponses sans citation ou avec BI-RADS / délai de suivi non présents dans les passages (détectés par l'agent 6). Correction : identifiant de passage donné en exemple ; interdiction d'inventer BI-RADS et suivi ; si refus du vérificateur → P2b ; sinon réponse extractive (aucun appel LLM).

Avant / après : v1 : instruction générale → citations parfois absentes. v2 : format [id] + exemple + interdits → réponse valide (valide=True, 0 problème) sur la question « recommandations de suivi ».

Prompt P2 :

```
Answer ONLY from the provided passages. Every statement must be followed
by the ID of the supporting passage in square brackets, for example
[bcmid_..._rapport_c0002]. If the information is missing, write exactly:
"Information not found in the available sources." Do not invent any
clinical observation, BI-RADS category or follow-up interval. Similar
images are not a diagnosis: draw no clinical conclusion from them.
PASSAGES: ... SIMILAR IMAGES: ... QUESTION: ...
```

P2b (reprise) :

```
IMPORTANT: every statement must be followed by the passage ID in square
brackets.
State nothing that is not written in the passages.
```

13.5 P3.v1 — Analyse image + texte

Rôle : Répondre sur les rapports de cas similaires retrouvés par l'image et par la question.

Technique : Garde-fous : le LLM n'a pas vu l'image ; séparation par patiente ; identifiants de type I2.1 (passage lié à une image) et R1 (recherche texte) ; langue de la question.

Échecs et correction : Observé : mélange possible entre patientes ; un contenu issu d'un autre contexte clinique apparaît dans une réponse. Correction : consigne « Keep each patient separate » + contrôle de la patiente par l'agent de vérification.

Avant / après : Sorties du test : toutes les citations valides (I2.1, R1. . .) ; réponses regroupées par patiente.

Prompt :

```
You answer questions about retrieved breast-imaging reports for research.
- You have NOT seen or analyzed the submitted image. It was used only
to retrieve similar training cases.
- Do not diagnose the query patient or transfer another patient's findings
to them.
- Keep each retrieved patient's information separate. Use only the evidence
below.
- Every bullet containing a report fact MUST end with its exact evidence
ID(s), such as [R1] or [I2.1].
- If the evidence is insufficient, say so. Answer in the language of
the question. Be concise.
```

13.6 P4.v2 — Générateur par passage (suivi et BI-RADS)

Rôle : Pour chaque passage, restituer l'intervalle de suivi explicite et la catégorie BI-RADS.

Technique : Sortie structurée par passage ; alias courts [E1. . .] remplacés par les vrais identifiants ; règles sur le vocabulaire ; une reprise.

Échecs et correction : Prévenu : la formule « satisfactory follow up » ne contient pas de recommandation de suivi ; le modèle pourrait la confondre. Correction : règle explicite + « No explicit follow-up interval stated. ». Observé : citations non conformes possibles ; correction : alias + retry « n'utilise que [E1], [E2]. . .».

Avant / après : v1 (question libre) : réponse correcte mais format variable. v2 : une entrée par passage, citations valides et complètes (2 sur 2), BI-RADS 2 + « annual follow up ».

Prompt :

```
Answer using only the report passages below. For EACH passage, provide
a separate entry containing:
1. The exact follow-up recommendation or interval stated in that passage.
2. The BI-RADS category, if stated.
```

```
Rules: look for explicit wording such as "annual follow up" or "close
follow up"; do not substitute "satisfactory follow up" or "no interval
changes" for an explicit recommendation; if not stated, write "No explicit
follow-up interval stated."; preserve the report's wording; cite each
entry with that passage's exact ID; do not combine information across
patients or invent facts.
```

Retry :

```
Retry: cite every factual statement using only the labels [E1], [E2]...Do
not cite patient IDs.
```

13.7 P5.v1 — Reclasseur (reranker)

Rôle : Réordonner les passages candidats (après RRF) selon leur pertinence pour la question.

Technique : Sortie JSON seule ; entrées tronquées à 900 caractères ; identifiants P0. . .Pn.

Échecs et correction : Observé/prévenu : JSON absent ou invalide, identifiants omis. Correction : extraction par expression régulière, complétion par l'ordre RRF, statut de repli (fallback_rrf_no_json / _error).

Avant / après : Statut « qwen_reranked » obtenu dans les exécutions texte et image + texte ; sinon ordre RRF conservé.

Prompt :

```
Rank these report passages by relevance to the user's question.
Use only their content and return JSON only: {"ranking":["P0","P1"]}
Question: {query} Passages: [P0] patient=... {texte[:900]} ...
```

13.8 P6.v1 — Légende BLIP-2 (fine-tuning)

Rôle : Consigne fixe associée à chaque image pour apprendre à produire des observations.

Technique : Consigne d'instruction constante ; cible = observations du rapport (en-tête et légende retirés).

Échecs et correction : Observé : après QLoRA, générations répétitives (boucles). Correction non aboutie : piste abandonnée au profit de la recherche de cas (Section 6).

Avant / après : Avant : gabarit « Ultrasound image 1 . . .» répété. Après : « No suspicious lymph nodes » répété. Perte 3,99 → 2,73 sans gain qualitatif.

Prompt :

> `Describe the breast imaging findings in English. (cible : texte « observations » du rapport)`

Annexe B — Évaluation détaillée du retrieval

Corpus réel (502 passages d'entraînement), recherche dense E5. Référence : patientes dont le texte contient l'expression. Les valeurs proviennent de l'exécution du notebook.

Requête	Intention	Langue	Réf.	k	Hits	P@k	Rappel@k	Rang 1er pertinent
annual_en	annual	en	114	5 / 10 / 20	5 / 10 / 20	1,00 / 1,00 / 1,00	0,04 / 0,09 / 0,18	1
annual_fr	annual	fr	114	5 / 10 / 20	5 / 10 / 20	1,00 / 1,00 / 1,00	0,04 / 0,09 / 0,18	1
close_en	close	en	13	5 / 10 / 20	3 / 4 / 6	0,60 / 0,40 / 0,30	0,23 / 0,31 / 0,46	1
close_fr	close	fr	13	5 / 10 / 20	0 / 0 / 2	0,00 / 0,00 / 0,10	0,00 / 0,00 / 0,15	11
biopsy_en	biopsy	en	2	5 / 10 / 20	1 / 1 / 1	0,20 / 0,10 / 0,05	0,50 / 0,50 / 0,50	1
biopsy_fr	biopsy	fr	2	5 / 10 / 20	1 / 1 / 1	0,20 / 0,10 / 0,05	0,50 / 0,50 / 0,50	1

Commentaires.

1. La précision parfaite sur « annual » reflète la fréquence de l'expression (114 patientes) ; elle prouve la cohérence lexicale plus que la finesse sémantique.
2. L'échec de « close_fr » est le principal défaut mesuré : le modèle multilingue relie mal « suivi rapproché » à « close follow up ».
3. « biopsy » n'a que deux références : P@k décroît mécaniquement avec k, et le second cas n'est jamais retrouvé.
4. Aucune comparaison chiffrée dense / BM25 / hybride / reranker n'a été conduite ; elle constitue la première amélioration à mener.

Test pilote

Test pilote (5 documents, 5 requêtes) : Hit@1 = Hit@3 = MRR@3 = 1,0 pour $k \in \{1, 3, 5\}$, avec une longueur de contexte moyenne de 371, 1 106 et 1 861 caractères respectivement.

Exemple hybride : pour « Quelles recommandations de suivi sont mentionnées ? », le top-5 fusionne des résultats sémantiques et lexicaux (RRF 0,0164 → 0,0159) ; le BM25 ramène un passage « BIRADS 3 for close follow-up » que la recherche dense seule classait plus bas.

Annexe C — Configuration et reproductibilité

Paramètre	Valeur
Graine / split	42 ; 232 / 50 / 50 patientes (entraînement / validation / test)
LLM	Qwen2.5-7B-Instruct, 4 bits NF4, double quantification, calcul fp16 ; décodage glouton ; 512 nouveaux tokens (agent)
Embeddings texte	intfloat/multilingual-e5-small, 384 d, normalisés, cosinus
Chunking	Paragraphes, 500 caractères, chevauchement ≈ 100, découpe sans couper les mots ; 502 passages
Retrieval	Candidats 20, BM25 (k1 1,5 ; b 0,75), RRF 60, reranker LLM ; top-5 ; seuil de similarité 0,30
Images	CLIP ViT-B/32, 1 381 images d'entraînement, une image par patiente, filtre de modalité
Agents	Réponse max 4 000 caractères ; passage tronqué à 1 500 ; 1 reprise du générateur puis repli extractif
BLIP-2 / QLoRA	opt-2.7b ; r 8, α 16, dropout 0,05 ; q_proj, v_proj ; lr 1e-4 ; 3 époques ; accumulation 8
Matériel	2 × Tesla T4 (Kaggle)

14. Conclusion

Ce projet avait pour objectif de concevoir et de mettre en œuvre un système multimodal d'aide à la recherche d'informations dans des rapports d'imagerie mammaire, en combinant des techniques de Deep Learning, de recherche d'information et de génération de texte par les grands modèles de langage. L'objectif principal était de faciliter l'accès aux informations pertinentes tout en garantissant la traçabilité des réponses et en limitant les risques liés à la génération de contenu médical non justifié.

Le travail réalisé a abouti à un pipeline fonctionnel intégrant plusieurs composants complémentaires : la recherche sémantique à l'aide des embeddings E5, la recherche lexicale BM25, la fusion des résultats par RRF, le reclassement des passages par un modèle de langage et l'exploitation de la similarité visuelle avec CLIP. Un mécanisme de génération augmentée par récupération (RAG) permet ensuite de produire des réponses fondées sur les documents retrouvés. Des agents de vérification contrôlent les citations, les informations cliniques sensibles et les risques de confusion entre patientes. L'ensemble est orchestré par n8n afin de proposer un workflow automatisé.

Les expérimentations ont permis de mettre en évidence l'intérêt de cette architecture, mais également ses limites. Les résultats du retrieval montrent notamment que les performances varient selon la formulation et la langue des requêtes. La difficulté à retrouver en français les passages associés à la notion de « suivi rapproché » illustre les limites de la recherche sémantique multilingue utilisée. De même, les essais de fine-tuning de BLIP-2 ont produit des générations répétitives malgré une diminution de la perte d'apprentissage. Ces observations ont conduit à privilégier une approche fondée sur la recherche de cas similaires et sur la vérification des informations récupérées, plutôt que sur la génération directe d'observations médicales à partir des images.

Une contribution importante du projet concerne la gestion des risques. La séparation des données par patiente, l'obligation de citer les sources, l'interdiction d'inventer des observations ou des recommandations de suivi, ainsi que la possibilité de s'abstenir lorsque les preuves sont insuffisantes constituent des mécanismes essentiels pour améliorer la fiabilité du système. Les analyses d'explicabilité ont également montré que les passages les plus similaires ne sont pas nécessairement ceux qui contribuent le plus à la réponse, ce qui souligne l'importance de ne pas confondre pertinence du retrieval et justification effective d'une génération.

Malgré ces résultats, plusieurs améliorations restent nécessaires. Les références utilisées pour évaluer la recherche doivent être renforcées par une annotation experte, et une comparaison quantitative entre recherche dense, BM25, approche hybride et reclassement doit être réalisée. L'alignement des images et des rapports au niveau de l'examen, l'intégration éventuelle d'encodeurs spécialisés en imagerie médicale et la réalisation de tests de robustesse plus approfondis permettraient également d'améliorer les performances. Enfin, une validation clinique indépendante serait indispensable avant d'envisager toute utilisation dans un environnement médical réel.

En conclusion, ce projet a permis de développer un prototype multimodal de recherche et d'assistance documentaire qui associe plusieurs méthodes de Deep Learning à des mécanismes de contrôle et de traçabilité. Les expérimentations ont montré que la fiabilité d'un tel système dépend non seulement de la qualité des modèles, mais aussi de la pertinence des données, de la rigueur de l'évaluation et de la capacité à reconnaître les limites des informations disponibles. Le système constitue ainsi une base de travail pour de futures recherches, avec une priorité donnée à l'évaluation experte, à la robustesse et à la sécurité des réponses, sans se substituer à l'expertise médicale.